



情报杂志  
*Journal of Intelligence*  
ISSN 1002-1965, CN 61-1167/G3

## 《情报杂志》网络首发论文

题目：基于时序聚合异构图的高价值专利识别方法研究  
作者：邓娜，喻卓群，孙俊杰，陈旭，刘树栋，孙湘怡  
网络首发日期：2025-01-17  
引用格式：邓娜，喻卓群，孙俊杰，陈旭，刘树栋，孙湘怡. 基于时序聚合异构图的高价值专利识别方法研究[J/OL]. 情报杂志.  
<https://link.cnki.net/urlid/61.1167.G3.20250117.0952.002>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于时序聚合异构图的高价值专利识别方法研究

邓娜<sup>1</sup> 喻卓群<sup>1</sup> 孙俊杰<sup>1</sup> 陈旭<sup>2</sup> 刘树栋<sup>2</sup> 孙湘怡<sup>3</sup>

(1. 湖北工业大学计算机学院 武汉 430068;  
2. 中南财经政法大学信息工程学院 武汉 430073;  
3. 湖北工业大学外国语学院 武汉 430068)

**摘要:** [研究目的] 提出一种基于时序聚合异构图的高价值专利识别模型,旨在解决现有高价值专利识别方法在利用专利异构关联和时序特征方面不足的问题,以更精确地识别高价值专利。[研究方法] 通过整合专利多模态信息并设计时序-引用影响力动态更新机制,生成反映专利价值变化的时序聚合异构图。构建融入双向注意力机制的异构图卷积网络模型,提高对专利异构特征的提取能力,实现对高价值专利的精确识别。[研究结果/结论] 实验表明,本文方法在智能电网领域的专利数据集上准确率和 F1 值分别达到 84.61% 和 84.59%,优于常规方法,验证了方法的有效性,为专利筛选和价值评估提供了新的视角和方法参考。

**关键词:** 高价值专利识别;异构图卷积网络;双向注意力机制;动态更新机制;多维特征  
**中图分类号:** G250.2; G306.0

## Research on High-Value Patent Identification Method Based on Time-Series Aggregated Heterogeneous Graphs

Deng Na<sup>1</sup>, Yu Zhuoqun<sup>1\*</sup>, Sun Junjie<sup>1</sup>, Chen Xu<sup>2</sup>, Liu Shudong<sup>2</sup>, Sun Xiangyi<sup>3</sup>

(1. School of Computer Science, Hubei University of Technology, Wuhan 430068;  
2. School of Information Engineering, Zhongnan University of Economics and Law, Wuhan 430073;  
3. School of Foreign Languages, Hubei University of Technology, Wuhan 430068)

**Abstract:** [Research purpose] This study aims to address the shortcomings of existing high-value patent identification methods in utilizing heterogeneous patent associations and time-series features, to identify high-value patents more accurately. [Research method] We propose a high-value patent identification model based on time-series aggregated heterogeneous graphs. This model integrates multimodal patent information and designs a dynamic update mechanism for time-series citation influence, generating a time-series aggregated heterogeneous graph that reflects changes in patent value. We construct a heterogeneous graph convolutional network model that incorporates a bidirectional attention mechanism to enhance the extraction capability of heterogeneous patent features, achieving precise identification of high-value patents. [Research result/conclusion] Experimental results show that our method achieves an accuracy of 84.61% and an F1 score of 84.59% on a patent dataset in the smart grid field, outperforming conventional methods. This validates the effectiveness of our approach and provides new perspectives and methodological references for patent screening and value assessment.

**Key words:** high-value patent identification; heterogeneous graph convolutional network; bidirectional attention mechanism; dynamic updating mechanism; multi-dimensional features

作者简介: 邓娜,女,1985年生,博士,副教授,研究生导师,研究方向:专利情报分析、自然语言处理、机器学习;喻卓群,男,2002年生,硕士研究生,研究方向:专利文本分析、自然语言处理;孙俊杰,男,1999年生,硕士研究生,研究方向:文本挖掘、机器学习;陈旭,男,1984年生,讲师,研究方向:专利分析系统、机器学习、深度学习;刘树栋,男,1984年生,副教授,研究方向:数据挖掘、机器学习、科技文献创新识别;孙湘怡,女,2001年生,硕士研究生,研究方向:国际情报分析、文本挖掘、机器翻译。

## 0 引言

近年来,我国在科技创新方面取得了显著进展,自主创新能力不断增强。随着国家对知识产权的日益重视,我国的专利申请数量不断攀升,已连续多年位居全球首位。在专利数量迅猛增长的背景下,如何从海量专利中识别出真正具有高价值的专利,已成为企业技术战略和知识产权管理的核心问题。高价值专利不仅能够体现技术的先进性和市场潜力,还能为企业带来长期的经济收益<sup>[1]</sup>。有效的高价值专利识别模型能够帮助企业优化资源配置、提升市场竞争力,并支持新产品研发<sup>[2]</sup>。同时,高价值专利也为企业在融资和市场评估中提供了重要依据,助力企业在全中国科技竞争中提高国际竞争力,实现知识产权保护与技术回报的稳定增长。

近年来在文本挖掘技术迅速发展的推动下,基于机器学习和深度学习的模型逐渐被应用到高价值专利识别的研究中<sup>[3]</sup>。然而,这些技术在理解专利深层次语义和提取专利异构特征方面仍显不足,难以全面揭示专利的语义信息与异构关联。专利文本通常隐含着与其他专利、技术领域、法律状态等多方面的复杂关系,单一的文本特征提取无法充分刻画专利的真实价值。此外,专利的影响力和价值往往会随着时间推移发生变化,现有方法常常忽略时间维度的重要性,尤其在应对新兴技术领域中的高潜力专利时,专利的时效性和前瞻性往往是其高价值的重要体现,如何有效利用专利的时序特征成为又一大挑战。针对上述不足与挑战,本文提出了一种基于时序聚合异构图的高价值专利识别方法,在专利异构关联和时序动态特征维度增强高价值专利识别的精度,为高价值专利的识别提供新的视角和方法支持,帮助企业在知识产权管理和技术创新中更加高效地识别和利用高价值专利。

## 1 相关研究

随着专利在技术创新中的重要性日益凸显,如何准确评估专利的价值成为了研究者们广泛关注的问题。传统上,用于专利价值评估方法主要分为定量和定性两大类,其一是基于经济学定量评估方法,该方法主要包括成本法、市场法和收益法,旨在通过经济学手段量化专利的市场价值<sup>[4]</sup>。例如,冉从敬等人<sup>[5]</sup>通过对专利的研发成本、维护费用等进行详细计算,利用成本法和机器学习算法估算专利的市场价值。这种方法强调专利的实际投入与支出,是评估专利价值的一个重要手段。市场法则基于类似专利的市场交易数据来评估专利的市场价格。而收益法则是通过预测专利未来的经济收益,并折现为现值,从而评估其潜在的市场

价值,但容易出现误差<sup>[6]</sup>。

其二是基于多维度指标体系的评估方法,该方法结合了定性与定量分析,不仅依赖于领域内专家和学者的综合评估,还通过多个维度对专利的价值进行全面分析。许华斌等<sup>[7]</sup>、吕晓蓉等<sup>[8]</sup>基于法律、技术和市场等多个维度,构建了三维专利价值评估体系,涵盖了专利的法律稳定性,还考虑了其技术创新性和市场前景,为更全面、深入的专利价值评估提供了理论依据。宋凯等<sup>[9]</sup>在法律、技术和市场的基础上,添加了战略价值维度,结合熵权 TOPSIS 模型和梯度提升树算法,深入分析了高校专利的技术转移价值。胡泽文等<sup>[10]</sup>系统归纳了高价值专利评估与识别领域的研究内容及层级结构,全面分析了专利在不同层级的价值体现。刘勤等<sup>[11]</sup>针对目前我国高价值专利评估中存在的科学性不足、定量指标较少及评估体系不完善等问题,提出了一套包含技术、法律、经济和市场等四个维度的高价值专利评估指标体系,并以江苏省获奖专利为测试样本,验证了该评估模型的有效性。Huang 等<sup>[12]</sup>通过结合灰色关联法和集群渗透算法,揭示了纳米领域核心专利的技术创新性和先进性,为高价值专利的识别提供了新的视角与方法论。李娟等人<sup>[13]</sup>在研究中通过结合层次分析法(AHP)与熵权法,使用10个二级指标,综合考虑了专利的技术先进性、市场规模、法律稳定性等多个方面,并以丰田开放专利为案例进行了验证。

与传统的定性和定量分析方法相比,机器学习模型能够自动从海量专利数据中提取特征,捕捉复杂的非线性关系,从而在高价值专利识别中表现出更高的精度和效率。王思培等<sup>[14]</sup>通过构建基于随机森林算法的专利预测模型,在“语音信号识别”领域的实证分析中,与逻辑回归、支持向量机、BP神经网络等方法进行对比,证明了算法的优良效果。Choi 等<sup>[15]</sup>使用前馈神经网络(FFN)搭建专利价值预测分析模型,通过分析专利的生命周期,评估其可能带来的商业价值。冯立杰等<sup>[16]</sup>提出一种结合 SAO 语义分析与多维技术创新地图的方法,利用 LDA 主题模型确定目标领域的关键技术问题,通过构建多维技术演化路径提出专利创新机会。

随着深度学习和复杂网络技术的快速发展,基于预训练增强模型和引文网络分析逐渐成为专利价值评估的研究热点。预训练增强模型通过对专利文本的语义信息进行深度挖掘,获取丰富的专利语义特征。孙冉等<sup>[17]</sup>基于 BERT 模型提取专利标题的语义特征,构建技术、市场、法律和专利权人的多特征融合的专利价值预测模型,展示了多特征融合模型在高价值专利预测中的优越性。薛航等<sup>[18]</sup>针对无线通信网络领域的

专利数据,引入对比学习在专利文本的语义编码方面进行了改进,通过过采样策略解决了专利价值识别中样本不均衡的问题。而基于引文网络的专利价值评估方法,一直是备受关注的研究热点。引文网络通过揭示专利之间的引用关系,能够有效反映专利的技术影响力和创新路径<sup>[19-20]</sup>。李姝影等<sup>[21]</sup>利用专利引用指标和引用滞后性特征,构建了基于引文网络的核心专利集筛选策略,作为技术主题识别的基础。此外,引文网络还能图神经网络提供结构化的图数据,进一步增强模型对专利间复杂关系的理解能力<sup>[22]</sup>。岳丽欣等<sup>[23]</sup>使用 Node2Vec 和 Doc2Vec 模型将专利引用和文本数据表示为高维向量,然后利用 LDA 主题模型进行技术主题识别,最过向量拼接融合了引用和文本特征,实现了专利技术创新路径的识别。吴杰等<sup>[24]</sup>通过构建包含专利核心词汇网络的图卷积网络(GCN),能够在少量专家标注的条件下,准确识别专利质量。

综上所述,当前学者们已对专利价值的评估、专利间关系的厘清等方面进行了积极探索,并取得了一定的进展与成效。但目前的研究仍然存在两大局限:①在处理专利文本的语义信息时,现有方法往往依赖于序列模型或单一类型的图结构,如引文同构图,忽略了专利文本其他异构信息的复杂关联,一定程度上限制了模型对专利间复杂语义和多维关系的同时挖掘能力;②传统模型在捕捉专利间动态关联与时序变化时,仍然缺乏有效的策略。现有研究大多使用静态的引文网络分析,未能充分利用时序特征来动态地捕捉专利之间的变化趋势与潜在价值,从而导致评估结果的滞后性和准确性不足。这些问题的存在,亟需引入更加复杂和智能化的图神经网络模型来同时处理异构信息与时序特征,以提高高价值专利识别的精度与效率。

2 研究方法

为解决上述问题,本研究提出一种基于时序聚合异构图的高价值专利识别的方法,旨在克服现有模型的局限性:

a. 针对现有方法难以同时处理专利多模态异构信

息的问题,本文通过构建专利异构图以全面整合专利文本、IPC 分类、法律状态及引用关系等多模态信息,为后续分析提供丰富异构数据;

b. 针对现有模型在捕捉专利间动态关联和时序变化方面的不足,本文提出了一种时序-引用影响力动态更新机制,通过结合时间影响因子和引用强度因子,对专利节点的权重进行实时动态调整,进而生成反映专利价值变化的时序聚合异构图;

c. 在此基础上,本文设计一种融入双向注意力机制的异构图卷积网络模型(HGCN-BiAttention),进一步提升对复杂语义和专利异构特征的提取能力,从而增强高价值专利的识别精度。

本文的研究流程包含以下 3 个部分:①获取专利数据与专利语义特征学习;②构建时序聚合异构图和获取专利异构特征;③特征融合与模型对比,具体流程如图 1 所示。

2.1 获取专利数据与专利语义特征学习

2.1.1 获取专利数据

样本构建的具体步骤如下:

a. 专利数据获取:通过检索专利数据库,获取目标领域内的专利数据,提取专利的关键特征,包括专利公开号、申请日期、标题、摘要、申请人、引用专利、法律状态等信息,为后续分析和特征构建提供基础数据。

b. 根据评价指标标记标签。针对所获取的专利数据,利用数据库提供的专利价值评估指标对样本进行标记,生成高价值专利的标签。进一步对数据集中的专利进行分类标注,增加一列标识项用于区分高价值专利与非高价值专利,这一过程为模型的监督学习提供了准确的标签信息。预处理后的部分专利数据如表 1 所示。

c. 获取时序特征和专利被引情况。时间维度的特征在高价值专利的识别中起着至关重要的作用。为精确捕捉专利的时间动态效应,本文将利用专利的时序特征,结合专利的被引次数,为引用-时序影响力动态更新模块提供重要输入,进而在模型中为每个专利赋予动态的时序权重。

表 1 预处理后的部分专利数据

公开号	标题	摘要	IPC 主分类	...	是否高价值专利(Y/N)
CN117833288A	一种预制舱式燃料电池 新型综合供能系统	本发明公开了一种预制舱式燃料电 池新.....支撑微电网运行。	H02J3/28	...	N
...	...	...	...	...	...
CN113435625A	电力系统动态经济调度 优化方法及设备	本发明公开了一种电力系统动态经 济调度优化方法.....的优化效果。	G06Q10/04	...	Y

2.1.2 基于 ERNIE 3.0 的专利深度语义学习

在现有的高价值专利识别研究中,许多方法主要依赖于专利的外部特征,如引用次数和市场表现等。

然而,专利文本本身,尤其是其中蕴含的创新性描述,也对专利价值的评估具有重要意义。ERNIE 3.0 是由百度提出的基于大规模中文语料库进行预训练的增强



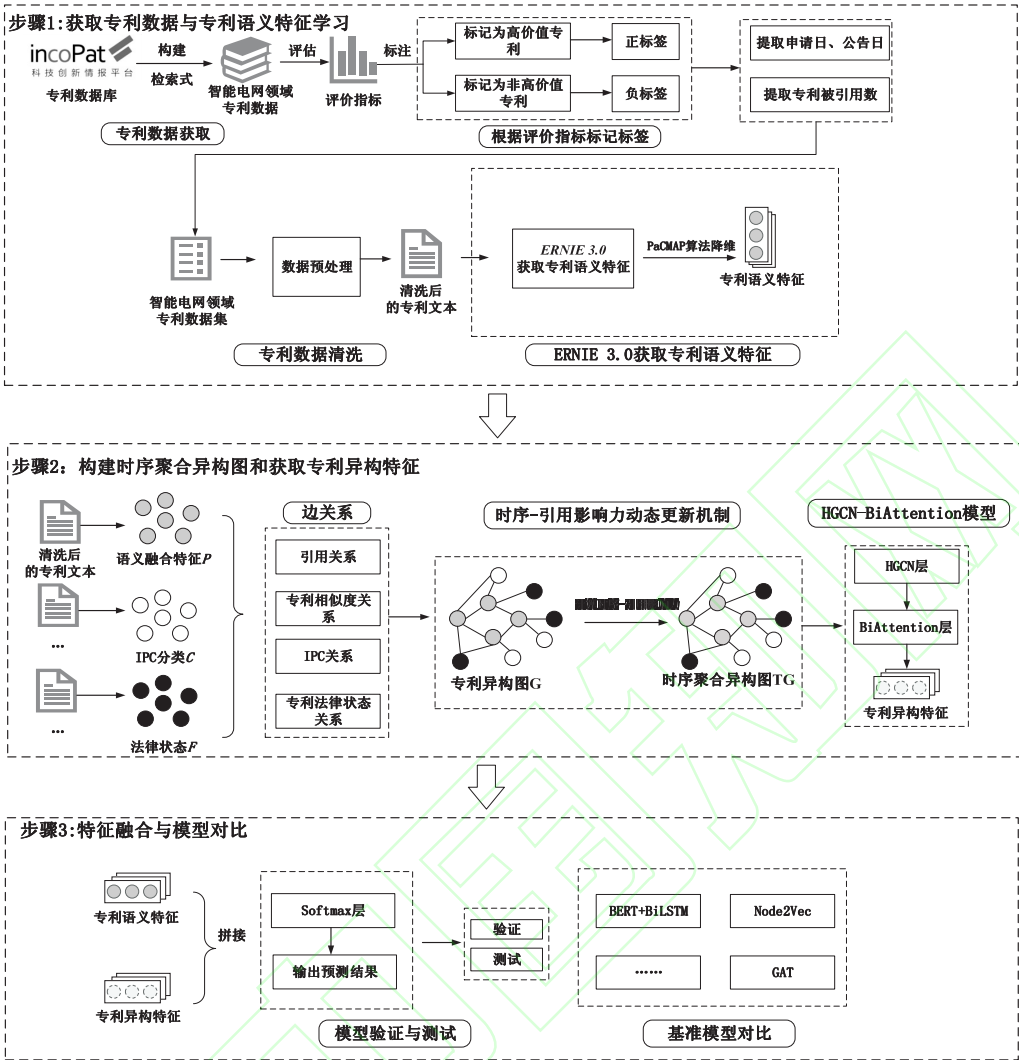


图1 研究框架图

型 BERT 模型,近年来在中文自然语言处理的多个任务中表现卓越,特别是在语义理解和信息抽取方面,展现了其强大的能力。如图 2 所示,经过数据清洗与预处理完成后,本研究利用 ERNIE 3.0 对每篇专利文本的标题与摘要进行编码,提取其深层语义特征。随后,采用 PaCMAP(Pairwise Constrained Manifold Approximation Projection)算法针对高维专利语义向量进行降维处理。通过最小化基于点对相似性的代价函数,PaCMAP 有效保留了数据的局部和全局结构,确保相似专利的语义向量在低维空间中更加接近,得到专利语义特征  $h_{\text{text}}$ 。

2.2 构建时序聚合异构图和获取专利异构特征

技术创新的演化过程往往展现出显著的动态性和累积性<sup>[25]</sup>,这种特性使得技术价值随着时间的推移而发生变化,进而影响到相关专利的引用关系和价值评估。因此,仅依赖于静态分析的方法往往难以全面捕捉专利的真实价值。传统的引文网络结构通过揭示专利间的直接引用关系,可以直观地展示技术知识的传播路径和影响力。然而引文网络主要集中于专利之间

的直接引用关系,难以捕捉专利间的多维度关联。多维度关联不仅包括专利的直接引用关系,还涉及专利相似性、技术分类、法律状态、共同市场竞争等多个维度的联系,这些信息能够更全面地反映专利的潜在价值和影响力。这些异构信息对于全面评估专利的真实价值至关重要,但在传统引文网络中往往被忽略或简化。

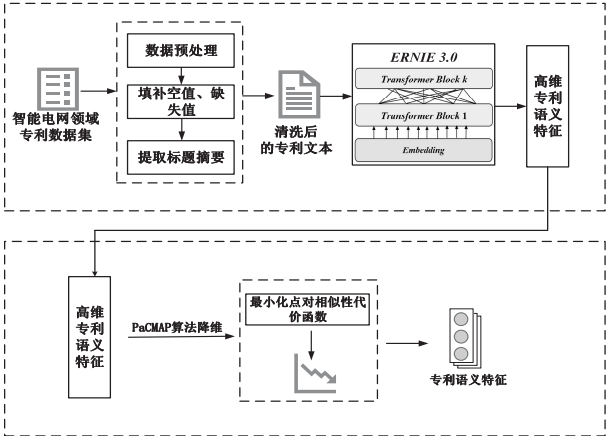


图2 获取专利语义特征流程图

### 2.2.1 专利异构图构建

基于上述考量,本文提出并设计了一种专利异构图网络,通过引入多种节点特征和关系,不仅能够捕捉到专利间的引用关系,还能整合各类关键信息,从而为专利价值的动态评估提供更为全面的支持。如图3所示,节点实体包括:专利语义信息、IPC 技术分类、法律状态。节点之间的关联关系包括:专利引用关系、专利相似度关系、专利 IPC 分类关系、专利法律状态关系。其中,专利相似度关系通过衡量专利文本之间的相似度,捕捉技术领域内的潜在关联性,将技术领先和具有重要市场应用前景的专利聚类在一起;专利 IPC 分类关系则通过揭示专利所属的技术领域,帮助模型理解专利的技术背景和创新点<sup>[26]</sup>;专利法律状态关系反映了专利的法律保护程度与有效性<sup>[27]</sup>,通过将法律状态纳入图结构中,得到专利的市场价值与技术竞争力综合信息。

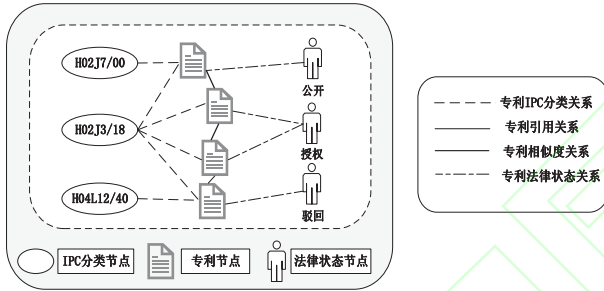


图3 专利异构图构建

专利异构图  $G = \{V, E\}$  包含了所有的节点实体  $V$  和节点之间的关联关系  $E$ , 其中  $V$  和  $E$  分别是专利异构图中节点的集合和边的集合。本研究中  $V = \{V_p, V_i, V_l\}$ , 分别表示专利 (Patent)、IPC 分类 (IPC Classification)、法律状态 (Legal Status);  $E = \{P-I, P-L, P-P, P^*-P^*\}$ , 分别表示节点之间的关系, 其中  $P-I$  表示专利 IPC 关系,  $P-L$  表示专利法律状态关系,  $P-P$  和

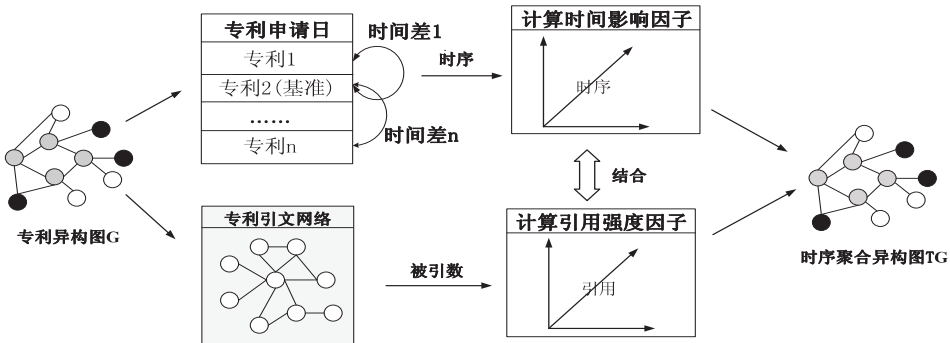


图4 时序-引用影响力动态更新流程

定义1: 时间差

首先, 定义专利  $P_i$  的时间差  $\Delta t_i$ , 表示专利  $P_i$  相对于基准时间的的时间差值。时间差  $\Delta t_i$  通过专利  $P_i$  的申请日  $t_i$  与数据集中最早专利的申请日  $t_0$  之间的绝对天数差计算得到。时间差反映专利在技术发展历程中

$P^*-P^*$  分别表示专利引用关系和专利相似度关系。具体专利异构图构建过程如算法1所示。

算法1 Patent Heterogeneous Graph Construction

```

1. INPUT: 专利数据集  $X = \{X^{(1)}, X^{(2)}, \dots, X^{(n)}\}$ 
2. 专利语义融合特征  $P_{\text{text}} = \{P_{\text{text}(1)}, P_{\text{text}(2)}, \dots, P_{\text{text}(n)}\}$ , 相似度阈值  $\tau$ 
3. OUTPUT:  $G = (V, E)$  // 专利异构图
4. BEGIN
5.  $V_p, V_i, V_l \leftarrow \text{extractPatentNodes}(P_{\text{text}}), \text{extractIPCNodes}(X), \text{extractLegalStatusNodes}(X)$ 
6.  $G.\text{add\_nodes}(V_p \cup V_i \cup V_l)$  // 添加专利、IPC 分类、法律状态节点
7.  $P-P \leftarrow \text{createCitationEdges}(X)$  // 获取专利引用边
8. For each  $P(i), P(j) \in V_p$  do
9.  $\text{Sim}_{i,j} \leftarrow \text{cosineSimilarity}(P_{\text{text}(i)}, P_{\text{text}(j)})$  // 计算专利相似度
10. if  $\text{Sim}_{i,j} > \tau$  then  $G.\text{add\_edge}(\text{createEdges}(P(i), P(j)))$  // 超过阈值, 添加专利相似度边
11. end for
12.  $G.\text{add\_edges}(P-P)$  // 添加专利引用边
13.  $G.\text{add\_edges}(\text{createEdges}(V_p, V_i))$  // 添加专利与 IPC 分类的边
14.  $G.\text{add\_edges}(\text{createEdges}(V_p, V_l))$  // 添加专利与法律状态的边
15. END

```

### 2.2.2 时序-引用影响力动态更新机制

技术创新的价值随着时间的推移而变化, 这种变化在专利的引用模式中尤为明显。为此, 本研究设计了一种动态更新机制, 通过结合时间影响因子 (Time Influence Factor) 和引用强度因子 (Citation Intensity Factor), 对专利节点的权重进行动态调整, 以捕捉时间维度对专利价值影响的动态特征。时间影响因子模拟了专利影响力随时间的变化, 而引用强度因子则衡量专利的被引用次数对其影响力的提升作用, 从而更全面地评估专利的动态价值, 具体流程如图4所示。

的相对时间位置:

$$\Delta t_i = |t_i - t_0| \quad (1)$$

定义2: 时间影响因子

时间影响因子  $\tau_i$  用于反映随着时间推移, 专利对后续技术的影响力变化的指标, 时间影响因子  $\tau_i$  定义

为:

$$\tau_i = \exp(-\lambda \cdot \Delta t_i) \quad (2)$$

其中,  $\lambda$  为时间影响速率的调节参数, 决定了时间对专利影响力的减弱速度。 $\tau_i$  模拟了时间对专利影响力的更新作用。时间影响因子  $\tau_i$  越小, 表明随着时间的推移, 专利对后续技术的影响力逐渐减弱。

定义 3: 引用强度因子

在确定了时间影响因子后, 还需要考虑专利的引用强度对其影响力的贡献。引用强度因子  $\gamma_i$  用于衡量专利被引用的次数对其影响力的提升效果, 计算公式为:

$$\gamma_i = \left( \frac{\log(1 + c_i)}{\log(1 + \max(c))} \right)^\alpha \quad (3)$$

公式中,  $\log(1 + c_i)$  是对专利  $P(i)$  的引用次数  $c_i$  进行对数变换, 以减小引用次数分布不均衡对模型的影响。 $\log(1 + \max(c))$  则是对最大引用次数进行归一化处理, 确保引用强度因子在不同专利之间具备可比性。通过调节参数  $\alpha$  来控制引用强度对专利权重的影响力度, 从而更准确地评估专利的实际影响力。在综合了时间影响因子  $\tau_i$  和引用强度因子  $\lambda$  后, 将专利的初始权重  $w_i^{(0)}$  进行更新:

$$w_i = w_i^{(0)} \cdot \tau_i \cdot \gamma_i \quad (4)$$

通过时间影响因子  $\tau_i$  和引用强度因子  $\gamma_i$  的综合考虑, 动态时序更新机制不仅有效捕捉了专利随时间推移的影响力变化, 还充分利用了引用次数对专利价值的增强作用。最终, 得到每个专利节点的动态更新权重  $w_i$  后, 将专利节点的原始特征与更新后的权重  $w_i$  结合, 构成每个节点的初始特征向量, 形成时序聚合图 TG:

$$h_i = [h_i^{\text{original}}, w_i] \quad (5)$$

这样不仅可以反映节点自身的特征信息, 还能够通过权重  $w_i$  体现专利的时序特征和引用强度, 为后续的特征聚合操作提供动态性基础。

### 2.2.3 基于 HGCN-BiAttention 的高价值专利识别模型构建

为了对专利时序聚合异构图中的多维信息进行深度挖掘与特征提取, 本文设计了一种基于融入双向注意力机制的异构图卷积网络 (HGCN-BiAttention) 的高价值专利识别模型, 通过捕捉专利之间的动态演化和交互特性, 从而提升高价值专利识别的准确性。具体过程如下:

利用异构图卷积网络对图中的节点进行特征聚合。与传统的 GNN 不同, HGCN 通过遍历多模态的邻居节点, 能够在多类型节点之间捕捉到更丰富的语义关系。对于专利异构图中的每个节点  $v$ , 多层卷积的操作可以表示为:

$$h_v^{(l+1)} = \sigma \left( \sum_{u \in N(v)} \frac{1}{c_{vu}} W^{(l)} h_u^{(l)} \right) \quad (6)$$

其中,  $h_v^{(l+1)}$  表示第  $l+1$  层中每个专利节点  $v$  的表示向量,  $N(v)$  表示专利节点  $v$  的邻居节点集合,  $c_{vu}$  是专利异构图节点  $v$  和  $u$  之间的归一化系数,  $W^{(l)}$  为第  $l$  层的可学习权重矩阵,  $\sigma$  是非线性激活函数。通过异构卷积能够有效整合来自专利文本、IPC 分类、以及法律状态等多源异构信息, 捕捉多类型节点间的语义关系。

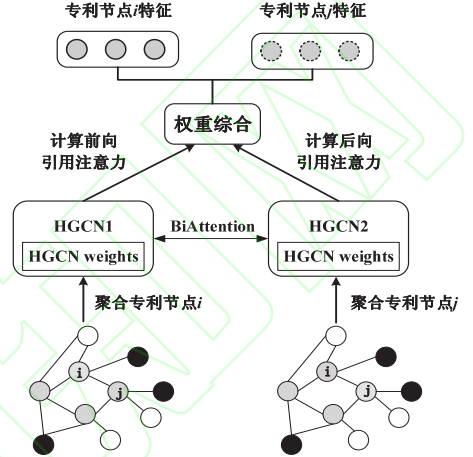


图 5 融入双向注意力机制的异构图卷积网络模型示意图

在 HGCN 提取的高维特征基础上, BiAttention 层进一步利用专利节点间的引用关系进行深入建模。如图 5 所示, 假设专利节点  $i$  对专利节点  $j$  存在引用关系, 在传统方法中通常仅关注专利节点  $i$  向专利节点  $j$  的单向引用, 无法同时反映专利节点  $i$  对专利节点  $j$  的技术依赖以及专利节点  $j$  对专利节点  $i$  的影响, 难以全面反映专利之间的复杂技术关联与影响力。

基于此, 本文引入双向注意力机制, 不仅限于专利节点  $i$  对专利节点  $j$  的借鉴作用, 还考虑到专利节点  $j$  被专利节点  $i$  引用后的潜在价值增益。前向引用反映了专利  $i$  对  $j$  的借鉴程度, 公式如下:

$$\alpha_{ij}^{\text{forward}} = \frac{\exp(\mathbf{a}^T [h_i \parallel h_j])}{\sum_{k \in N(i)} \exp(\mathbf{a}^T [h_i \parallel h_k])},$$

$$\alpha_{ij}^{\text{backward}} = \frac{\exp(\mathbf{a}^T [h_j \parallel h_i])}{\sum_{k \in N(j)} \exp(\mathbf{a}^T [h_j \parallel h_k])} \quad (7)$$

其中,  $\alpha_{ij}^{\text{forward}}$  表示前向注意力权重,  $h_i$  和  $h_j$  是分别表示专利  $i$  和  $j$  的特征向量,  $\mathbf{a}$  是可学习的权重向量。分母中的  $N(i)$  是节点  $i$  的邻居节点集合, 用于归一化所有邻居的注意力权重。

同时, 后向注意力机制计算与之类似,  $\alpha_{ij}^{\text{backward}}$  表示后向注意力权重, 专利节点  $j$  被  $i$  引用后带来的技术权威性增强也被加权考虑。相比于单向的异构图注意力机制, 这种双向注意力权重的设置, 能够在特征聚合时实现更丰富的技术关联建模, 有助于准确识别出对

整体专利网络具有高价值和核心作用的专利节点。最后,前向和后向的注意力权重被综合起来,得到节点的最终特征,其中  $W$  和  $b$  是可学习的权重矩阵和偏置项,ReLU 是激活函数,用于增加非线性表达能力。公式如下:

$$h_i^{\text{final}} = \text{ReLU}\left(W \left[ \sum_{j \in N(i)} \left( \frac{\alpha_{ij}^{\text{forward}} + \alpha_{ij}^{\text{backward}}}{2} \right) h_j + h_i \right] + b \right) \quad (8)$$

### 2.3 特征融合与模型对比

通过异构图卷积网络和双向注意力机制提取专利异构特征  $h_i^{\text{final}}$  后,为了更全面地评估专利的价值,本研究采用了特征拼接的方式。如图 6 所示,将专利异构特征与 2.1.2 节通过 ERNIE 3.0 模型与 PaCMAP 算法得到的专利语义特征  $h_{\text{text}}$  进行融合,形成一个包含专利语义信息与异构信息的综合特征表示,使得模型不仅能够了解专利的技术内容,还能够掌握专利在技术网络中的位置和关系,从而实现更全面的专利价值评估。

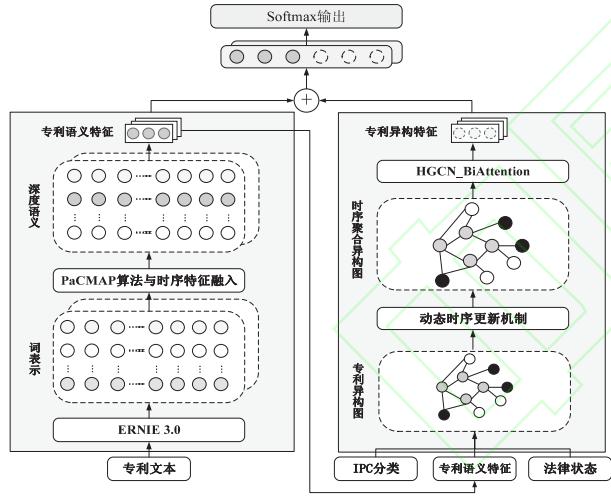


图 6 基于 HGCN-BiAttention 模型与特征融合框架

最后,使用 Softmax 分类器进行高价值专利识别,公式如下:

$$h_{\text{fused}} = [h_i^{\text{final}}; h_{\text{text}}] \quad (9)$$

$$\hat{y} = \text{Softmax}(W_t \cdot h_{\text{fused}} + b) \quad (10)$$

其中,  $\hat{y}$  为预测的高价值专利概率分布,  $W_t$  和  $b$  为分类器的权重矩阵和偏置向量。本研究中高价值专利识别是二分类问题,故模型损失函数使用二元交叉熵损失函数,通过衡量预测结果与专利价值真实标签之间的差异,来指导模型参数的更新。

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)] \quad (11)$$

其中,  $L$  为损失值,  $N$  为专利样本数量,  $y_i$  为第  $i$  个专利样本的真实标签,  $\hat{y}_i$  为模型预测第  $i$  个专利样本的概率。通过最小化该损失函数,模型能够逐渐提

升对高价值专利的识别准确性。为了全面评估所提方法的有效性,本研究选择了 BERT\_BiLSTM、DeepWalk、Node2Vec、GCN 和 GAT 五种模型作为对比实验的基线模型,通过对比不同的网络结构和特征处理方式,来评价本文模型在高价值专利识别任务中的优势与性能。

## 3 实验与结果分析

### 3.1 数据来源

随着全球能源需求的增长和环境保护意识的增强,电力系统的可持续性和稳定性成为各国政府关注的重点。2022 年国家能源局印发的《“十四五”可再生能源发展规划》进一步指出,明确促进可再生能源高质量发展和加快能源绿色低碳转型的战略目标。智能电网技术作为实现这一目标的重要手段,通过优化电力资源配置、提高能源利用效率,保障了能源安全性和可持续性<sup>[28]</sup>。基于此背景,本研究针对智能电网领域的专利数据进行分析,使用 incoPat 全球专利数据库作为数据来源,并结合智能电网领域专家的意见,筛选 IPC 技术分类为 H02J 的“智能电网供电系统”、H04L 的“智能电网局部或外部之间的通信”等的智能电网领域数据作为样本,检索式为  $TS = ((\text{"智能电网"} \text{ OR "Smart Grid"} \text{ OR "电网智能化"} \text{ OR "电力系统"} \text{ OR "电网监控"} \text{ OR "电力调度"})) \text{ AND } (IPC = H02J * \text{ OR } IPC = H04L * \text{ OR } IPC = H04B * \text{ OR } IPC = G05F * \text{ OR } IPC = Y04S * )$ ,将专利时间区间设置为 2006 年-2024 年,共检索到 93956 条专利数据,以此作为样本基础进行研究。

首先,根据 incoPat 全球专利数据库提供的合享价值度进行高价值专利样本筛选,该指标综合考虑了技术稳定性、先进性、保护范围等因素对专利价值进行了评估,数值范围为 1-10,其中合享价值度数值越高表示价值越大<sup>[29]</sup>。因此,将合享价值度值为 10 的专利数据作为高价值专利的正样本,共筛选出 10000 条高价值专利样本。为了在不损失专利间引用关系的前提下,同时保持正负样本的均衡性,本研究随机选择 14427 条的非高价值专利作为负样本,确保高价值与低价值专利样本的比例接近均衡。从 incoPat 全球专利数据库下载专利数据构建数据集,包含专利标题、摘要、申请人、公开(公告)号等关键性字段信息,最后将其按照 8:2 划分为训练集、测试集,用于模型参数的学习以及性能评估,具体如表 2 所示。

通过反复进行实验,最终确定最优的网络参数进行高价值专利识别的任务:ERNIE 3.0 的最大序列长度为 512,PaCMAP 算法使用欧几里得距离作为度量,降维到 512 维,异构图卷积网络层数为 2 层,第一层卷积隐藏层维度为 256,第二层卷积隐藏层维度为 128,



时间影响因子为 0.01,引用增强因子为 0.5,相似度阈值为 0.9,双向注意力头数为 12,全连接层维度为 2,学

习率为 0.001,训练轮数为 500,模型优化器使用 Adam 优化器。

表 2 数据集构成

数据集	类型	数量	占比/%
训练集(80%)	2006 年-2024 年“智能电网”领域高价值专利	8000	40.94
	2006 年-2024 年“智能电网”领域非高价值专利	11541	59.06
测试集(20%)	2006 年-2024 年“智能电网”领域高价值专利	2000	40.93
	2006 年-2024 年“智能电网”领域非高价值专利	2886	59.07
总计	—	24427	100

3.2 实验指标

本文采用了准确率 ACC、精确率 P、召回率 R 和 F1 分数这四项评估指标来衡量模型在高价值专利识别任务中的性能。准确率衡量模型预测正确的样本数占总样本数的比例,反映了模型在识别高价值和低价值专利时的整体表现;精确率关注的是模型在所有预测为高价值专利的样本中,实际为高价值专利的比例;召回率则衡量模型从所有实际高价值专利中正确识别出的比例,体现了模型的检索能力;F1 分数则是准确率和召回率的调和平均,提供了对模型整体性能的综合评价。具体公式如下:

$$Acc = \frac{TP+TN}{TP+TN+FP+FN} \tag{12}$$

$$P = \frac{TP}{TP+FP} \tag{13}$$

$$R = \frac{TP}{TP+FN} \tag{14}$$

$$F1 = 2 \times \frac{P \times R}{P + R} \tag{15}$$

其中,TP 为模型正确识别的高价值专利数;TN 为模型正确排除的低价值专利数;FP 为模型错误识别为高价值专利的数量,FN 为模型漏掉的高价值专利数量。

3.3 实验对比与结果分析

在本节中,我们将本文提出的高价值专利识别模型与其他主流模型进行实验对比分析,选择了 BERT-BiLSTM、DeepWalk、Node2Vec、GCN、GAT 五种主流模型作为对比对象。这些模型在处理文本和图结构数据时具有广泛的应用,能够从不同角度挖掘专利的特征和关系。

BERT-BiLSTM:使用 BERT 提取专利标题和摘要的深度语义特征,生成文本的上下文表示。然后,将这些表示输入到双向长短期记忆网络(BiLSTM)中,BiLSTM 用于进一步处理文本特征,生成最终的特征向量。

DeepWalk:在专利引用网络中,通过随机游走的方式捕捉专利节点之间的引用关系。每次随机游走生成的节点序列反映了专利之间的引用路径,通过对这

些序列进行嵌入,生成低维度的节点向量表示。

Node2Vec:与 DeepWalk 类似,在专利网络中引入了可调节的随机游走策略,通过设置返回概率和邻域探索概率,灵活捕捉专利节点的局部和全局结构特征。

GCN:通过图卷积操作对专利网络中的节点特征进行聚合,生成每个节点的嵌入表示,提取专利与其邻居节点之间的关系信息,有效捕捉专利节点在网络中的本地结构特征。

GAT:引入注意力机制,使得每个节点能够根据其邻居节点的重要性自适应地调整权重,从而生成更加精细的节点嵌入表示,通过注意力机制增强了模型对专利间关系的建模能力。

表 3 实验对比

模型	Acc	P	R	F1
BERT-BiLSTM	77.45	76.39	78.32	77.10
DeepWalk	71.85	70.95	72.40	68.75
Node2Vec	72.38	71.27	73.12	69.42
GCN	75.48	74.63	76.25	75.38
GAT	78.54	77.45	79.23	78.17
本文模型	<b>84.61</b>	<b>84.58</b>	<b>84.61</b>	<b>84.59</b>

根据表 3 的结果,GCN 模型相比于 DeepWalk 和 Node2Vec 模型在各个指标上都有显著提升。特别是在 F1 值上,GCN 相比于 DeepWalk 和 Node2Vec 分别提高了约 6.63 和 5.96 个百分点,主要原因在于不仅利用了引文关系,还更好地结合了图卷积网络的局部邻域信息,能够更有效地捕捉专利间复杂的结构特征与关联信息。BERT-BiLSTM 模型相比于 GCN 模型在 F1 值上提高了约 1.72 个百分点,主要得益于预训练模型在捕捉文本特征方面的强大能力,使得模型能够更好地理解专利文本的语义信息。然而,由于模型对图结构信息的整合能力相对较弱,因此在整体表现上稍逊于引入了图结构信息处理机制的 GAT 模型。GAT 通过引入自注意力机制,允许模型在处理节点信息时,根据不同节点的重要性差异赋予不同的权重,相比于 GCN 模型在准确率、精确率、召回率和 F1 值分别提升 3.06、2.82、2.98 和 2.79 百分点。本研究通过整合多种节点类型和关系构建专利异构信息,同时引入时序-引用影响力更新机制,进一步提升了模型对

专利关系动态特征的捕捉能力,与 GAT 模型相比,在各个指标上分别提升 6.07、7.13、5.38 和 6.42 个百分点,充分证明了该模型在捕捉专利关系动态特征和异构信息整合方面的优势。

3.4 消融实验

为了全面评估本研究中不同的专利异构信息及注意力机制对模型性能的影响,本文设计了以下几种详细的消融实验,见表 4:

Exper0 表示作为本文实验的基础模型,仅保留异构图卷积网络和基本特征,去除掉注意力机制;Exper1 表示在基础模型上加入自注意力机制,实验结果表明,F 1 值从 83.33% 提升至 83.83%,表明自注意力机制在特征融合过程中起到了一定作用,但提升幅度有限,原因是自注意力机制在捕捉节点间的局部关联性上有

所欠缺;Exper2、Exper3 分别表示移除部分专利异构特征(IPC 分类和法律状态),以评估这些特征对模型性能的具体贡献。结果表明,Exper2 中移除 IPC 分类后,F 1 值下降了 2.37 百分点,Exper3 中移除法律状态特征后,F 1 值下降了 2.14 百分点。这表明,专利异构图中的 IPC 分类和法律状态特征在提升模型性能方面都具有一定作用,能够帮助模型更好地理解专利所属的技术领域与法律有效性。Exper4 表示,在移除本研究的时序-引用影响力更新机制之后,模型在各个指标上分别下降了 1.86、2.42、1.69 和 2.19 百分点,结果表明该机制在捕捉专利引用行为的时间动态特征方面发挥了关键作用,提升了模型对引用模式中重要专利的识别能力,从而提升整体性能。

表 4 消融实验对比

序号	模型	特征类型	Acc	P	R	F1
Exper0	HGCN	标题摘要+IPC 分类+法律状态+时序特征	83.28	83.43	83.28	83.33
Exper1	HGCN-SelfAttention	标题摘要+IPC 分类+法律状态+时序特征	83.91	83.85	83.91	83.83
Exper2	HGCN-BiAttention	标题摘要+法律状态+时序特征	82.55	81.98	82.87	82.22
Exper3	HGCN-BiAttention	标题摘要+IPC 分类+时序特征	82.73	82.24	83.17	82.45
Exper4	HGCN-BiAttention	标题摘要+IPC 分类+法律状态	82.75	82.16	82.92	82.40
Exper5	HGCN-BiAttention(本文模型)	标题摘要+IPC 分类+法律状态+时序特征	84.61	84.58	84.61	84.59

3.5 专利异构图网络层数实验

在本节中,我们针对专利异构图卷积网络模型的层数对模型性能的影响进行了实验。我们分别设置了不同的网络层数(1 到 5 层),以观察模型性能的变化。实验结果如图 7 所示,无论是本文提出的 HGCN-BiAttention 模型还是基础的 HGCN 模型,2 层网络结构均取得了最佳性能。随着网络层数的增加,模型的 F 1 值呈现出下降的趋势。对于 HGCN-BiAttention 模型,当层数超过 2 层时,模型性能逐渐下降,可能是由于信息过度聚合导致特征冗余性增加,进而影响模型的区分能力。同样,对于基础的 HGCN 模型,过多的层数也会导致性能的退化,这说明在特征提取过程中存在一个最佳深度。因此,2 层异构图卷积网络在本实验中表现出了较好的平衡性,能够有效捕获专利图中的复杂特征关系。




图 7 专利异构网络层数实验

3.6 引用强度和时间影响调节参数敏感实验

在进行时序-引用影响力动态更新过程中,引用强度因子和时间影响因子的设置对模型性能有着显著影响。时间影响因子则控制了时间对专利影响力的衰减速率,而引用强度因子调节了专利被引用次数对其影响力的提升效果。为了更好地理解这些参数对模型分类结果的影响,本文选择了 6 组不同的引用强度和时间影响的调节参数组合进行实验,具体组合如表 5 所示。

表 5 参数组合对比

名称	引文强度	时间影响	参数组合
LCI-LTI	0.1	0.001	低引文强度,低时间影响
LCI-MTI	0.1	0.01	低引文强度,中等时间影响
MCI-MTI	0.5	0.01	中等引文强度,中等时间影响
HCI-MTI	0.9	0.01	高引文强度,中等时间影响
MCI-HTI	0.5	0.1	中等引文强度,高时间影响
HCI-HTI	0.9	0.1	高引文强度,高时间影响

如图 8 的实验结果所示,不同的参数组合对模型性能的影响显著。首先,LCI-LTI 组合(低引文强度,低时间影响)表现较弱,主要原因在于模型对新专利的引用影响较小,导致较为平衡但不突出的性能。其次,LCI-MTI 组合(低引文强度,中等时间影响)通过略微增加时间影响因子,提升了模型对较新专利的关注度,F 1 值上升至 83.70%,模型能够更有效地捕捉新旧专利之间的动态关系,从而在各项指标上有小幅

提升;随着引用强度因子和时间影响因子的进一步优化,MCI-MTI 组合(中等引文强度,中等时间影响)的 F1 值达到最佳,表明在适中参数下,模型能够较好地平衡新旧专利的影响,在专利数据的动态特征捕捉上表现优越,成为实验中的最优配置;HCI-MTI 组合(高等引文强度,中等时间影响)尽管引用强度较高,但由于时间影响因子适中,仍能保持较高的性能;然而,当时间影响因子进一步增大至 0.1 时,MCI-HTI(中等引文强度,高等时间影响)和 HCI-HTI(高等引文强度,

高等时间影响)组合开始表现出性能下降的趋势,F1 值分别下降至 83.95% 和 83.65%,说明过高的时间衰减可能导致模型过度关注新专利,忽略历史专利价值的重要性,从而影响整体性能。因此,根据上述大量的引用强度和时间影响的调节参数敏感实验,本研究使用的 MCI-MTI 组合(中等引文强度,中等时间影响)能平衡新旧专利影响,验证了本文方法在捕捉专利时序特征和引用动态方面的适应性和稳健性。

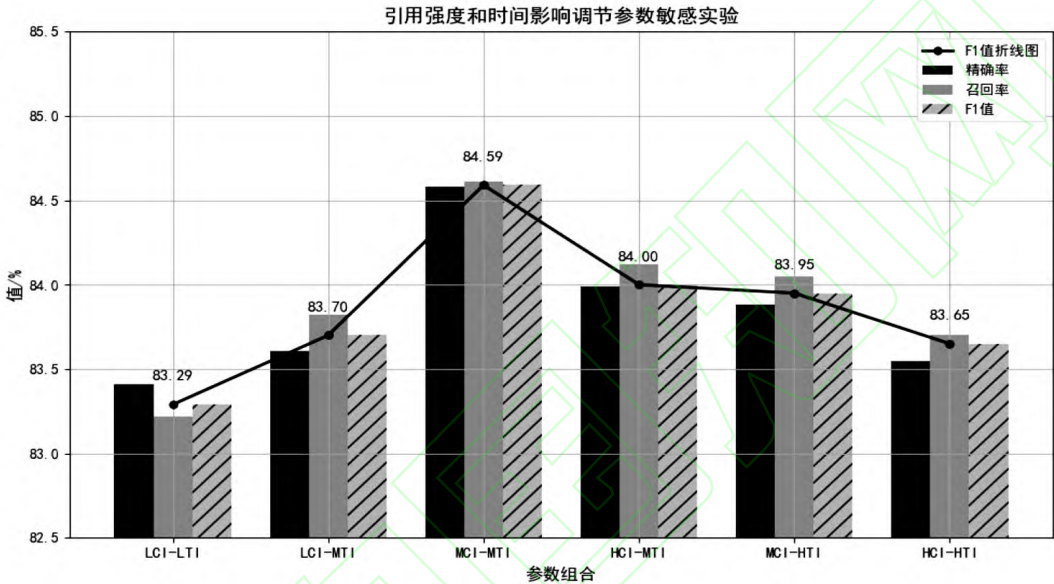


图 8 超参数敏感实验对比

4 结 语

本文针对当前高价值专利识别模型在多维异构信息整合与时序动态特征捕捉方面的局限性,提出了一种基于时序聚合异构图的高价值专利识别方法。通过整合包含专利文本、IPC 分类、法律状态等多模态异构信息,并引入时间-引用影响力动态更新机制,本文实现了对时序聚合异构图的动态建模,有效弥补了传统静态分析方法的不足。同时,设计了一种融入双向注意力机制的异构图卷积网络模型(HGCN-BiAttention),通过赋予节点间前向和后向的注意力权重,全面捕捉引用专利和被引专利之间的相互影响关系,从而提升模型对专利间复杂技术关联和影响力的理解深度。

本研究为高价值专利的识别提供了一种新的视角和方法支持,通过深入揭示专利技术的时序演化和多维信息,能够为企业的技术战略决策和知识产权布局提供科学支持,促进了知识的有效转移和产业应用。然而,本研究仍存在一些局限性。尽管引入了多维特征与时序动态特征,但在特征选择上仍有待进一步扩展,其次,由于双向注意力机制和异构图卷积网络的引

入,模型的计算复杂度有所增加,未来的研究可以进一步优化图结构和注意力机制,以更高效地处理大规模专利数据。同时,提升模型在跨领域应用中的适应性,拓展模型的应用范围和改进方法,以更好地服务于企业和研究机构的专利管理与战略布局。

参 考 文 献

[1] 李黎明. 专利价值研究的文献综述与未来展望[J]. 情报杂志,2023, 42 (2): 166-174.

[2] 黄先海,王瀚迪,孙涌铭,等. 数字技术与企业出口质量升级——来自专利文本机器学习的证据[J]. 数量经济技术经济研究, 2023,40 (12): 69-89.

[3] 陈 玉,胡泽文,周西姬. 国际高价值专利:概念内涵、主题范畴、多维价值指标与评估预测方法综述[J]. 现代情报, 2024,44 (8): 153-170.

[4] 万小丽,朱雪忠. 专利价值的评估指标体系及模糊综合评价[J]. 科研管理,2008,29 (2): 185-191.

[5] 冉从敬,李 旺,胡启彪,等. 基于机器学习的成本法在专利价值评估中的应用研究——以“新能源汽车”为例[J]. 现代情报,2024 (5): 140-152.

[6] 刘 妍. 专利价值评估研究综述与趋势展望[J]. 图书情报工作,2022,66 (15): 127-139.

[7] 许华斌,成 全. 专利价值评估研究现状及趋势分析[J]. 现

代情报,2014,34 (9): 75-79.

- [8] 吕晓蓉. 专利价值评估的动态模拟方法研究[J]. 科技进步与对策,2017,34 (3): 117-122.
- [9] 宋凯. 高校专利技术转移价值评估研究——基于熵权 TOP-SIS 模型和梯度提升树算法[J]. 情报杂志,2021,40 (7): 52-57.
- [10] 胡泽文,周西姬,任萍. 基于扎根理论的高价值专利评估与识别研究综述[J]. 情报科学,2022,40 (2): 183-192.
- [11] 刘勤,杨壬淦,刘友华. 高价值专利评估方法、存在问题及对策[J]. 科技管理研究,2022,42 (4): 147-152.
- [12] Huang L, Liu F, Zhang Y. Overlapping community discovery for identifying key research themes[J]. IEEE Transactions on Engineering Management,2021,68 (5): 1321-1333.
- [13] 李娟,李保安,方晗,等. 基于 AHP-熵权法的发明专利价值评估——以丰田开放专利为例[J]. 情报杂志,2020,39 (5): 59-63.
- [14] 王思培,韩涛. 基于随机森林算法的潜在高价值专利预测方法研究[J]. 情报科学,2020,38 (5): 120-125.
- [15] Choi J, Jeong B, Yoon J, et al. A novel approach to evaluating the business potential of intellectual properties: A machine learning-based predictive analysis of patent lifetime[J]. Computers & Industrial Engineering,2020,145: 106544.
- [16] 冯立杰,周炜,王金凤,等. 基于 SAO 语义分析的多维技术演化路径与技术创新机会识别研究[J]. 情报学报,2022,41 (11): 1149-1160.
- [17] 孙冉,安璐,李纲. 多特征融合的专利价值预测——以 5G 技术为例[J]. 现代情报,2022,42 (11): 87-96.
- [18] 薛航,施国良,陈挺. 基于对比学习的高价值发明专利识别——以无线通信网络领域为例[J]. 情报杂志,2024,43 (9): 179-187.
- [19] 冯立杰,秦浩,张珂,等. 基于离群专利和多维技术创新地图的技术机会识别路径研究[J]. 情报理论与实践,2023,46 (9): 79-86.
- [20] 张子岩,张俊艳. 基于高质量专利的储能关键技术国际竞争态势[J]. 储能科学与技术,2022,11 (1): 321-334.
- [21] 李姝影,张鑫,许轶,等. 核心专利集筛选及专利技术主题识别影响[J]. 情报学报,2019,38 (1): 13-20.
- [22] Han S, Huang H, Huang X, et al. Core patent forecasting based on graph neural networks with an application in stock markets[J]. Technology Analysis & Strategic Management, 2024, 36 (8): 1680-1694.
- [23] 岳丽欣,刘自强,刘春江,等. 融合引用和文本特征的技术创新路径识别研究[J]. 图书情报工作,2023,67 (3): 49-60.
- [24] 吴洁,桂亮,刘鹏. 基于图卷积网络的高质量专利自动识别方案研究[J]. 情报杂志,2022,41 (1): 88-95,124.
- [25] Smojver V, Štorga M, Zovak G. Exploring knowledge flow within a technology domain by conducting a dynamic analysis of a patent co-citation network[J]. Journal of Knowledge Management,2021,25 (2): 433-453.
- [26] Fischer T, Leidinger J. Testing patent value indicators on directly observed patent value—An empirical analysis of Ocean Tomo patent auctions[J]. Research Policy,2014,43 (3): 519-529.
- [27] Kim Y K, Park S T. Patent litigation research trends and trend analysis[J]. Journal of Computational and Theoretical Nanoscience,2021,18 (5): 1485-1489.
- [28] 熊谦,唐文哲,李银生. 可再生能源系统技术框架与关联模式——基于国内外专利数据的实证研究[J]. 水力发电学报,2023,42 (10): 13-26.
- [29] 曹琨,吴新年,白光祖,等. 基于专利文献的“卡脖子”技术识别研究——以数控机床领域为例[J]. 图书情报工作,2023, 67 (19): 80-91.